面向微小缺陷的多尺度特征匹配改进方案

以 MoEAD 为基础模型的论文研究与实验设计

整理日期：2026 年 11 月 10 日　版本：研究设计稿 v1.0

1 研究目标与证据边界

核心问题：如何在保持 MoEAD 参数效率的同时，通过保留细粒度特征、限制异常重建和协调多尺度残差，提高微小异常在固定误报率下的可检出性？

“提高异常分数”应理解为扩大微小缺陷与正常纹理的分数间隔，而非简单放大数值。对所有分数乘同一正系数，不改变排序，也不会改善 AUROC。

当前状态：本方案依据已读论文及官方代码接口提出，尚未完成服务器训练、消融或性能验证。文中的模块组合、尺寸和损失属于候选设计，不是已证实的论文结论。代码修改与实验由研究者在服务器执行。

1.1 原版模型的可验证瓶颈

官方配置将 EfficientNet-b4 的 stage 1–4 特征统一至 stride 16，即 224×224 输入对应 14×14 特征网格，再拼接进入共享参数的 SMoE 重建网络。原始与重建特征的通道 L2 距离上采样后形成异常图；图像级 max 评价配置另使用 16×16 平均池化。

1. **细节损失：**浅层的弱缺陷响应可能在统一缩放前后被削弱。
2. **异常复制：**增加细节容量后，模型也可能更准确地恢复异常。
3. **尺度失衡：**正常残差幅值大的尺度可能压过微弱但有效的细节响应。

1.2 文献依据与可借鉴范围

文献	可借鉴的设计	本方案中的用途
MoEAD [1]	参数共享、堆叠专家	控制双分支参数成本
Dinomaly [2]	低 / 高语义分组、含噪瓶颈	保留层次差异，限制过度重建
DeCo-Diff [3]	局部扰动、正常区域保持	分区域恢复训练
OneNIP [4]	正常目标恢复、残差细化	细节保留与恢复监督
CADA [5]	正常分数基准校准	分尺度残差校准的启发

2 模块 A：细节与语义双分支重建

设计：在统一缩放之前分出浅层细节支路，保留较高空间分辨率；深层语义支路维持原有粗尺度。分别重建、计算残差，最后融合异常图。

冻结的 EfficientNet-b4

浅层特征 $\longrightarrow$ 28×28 细节支路 $\longrightarrow$ 细节重建与残差

深层特征 $\longrightarrow$ 14×14 语义支路 $\longrightarrow$ 语义重建与残差

两支路尽量共享 SMoE；保留独立投影、位置编码和必要的归一化

分尺度校准 $\longrightarrow$ 残差融合 $\longrightarrow$ 像素异常图

28×28 与 14×14 是在输入分辨率不变时的初始对照配置，并非最优结论。浅深层划分可从前两层与后两层开始；固定划分后再做层选择实验，避免同时改变过多因素。

2.1 与已有方法的关系

Dinomaly 的分组主要针对同分辨率 ViT 的语义层次；这里拟研究的是 CNN 的不同空间尺度。MoEAD 已包含多层特征拼接，不能将“加入多尺度特征”本身作为创新。候选贡献应落在**空间尺度分工、共享重建以及细粒度异常证据保留**上。

2.2 防止直接复制与计算膨胀

干净浅层特征作为重建目标，不能通过无约束跳跃连接直接进入输出。各分支可保留邻域掩码，掩码窗口需结合尺度、特征步长与输入空间覆盖范围独立消融。

28×28 相比 14×14，token 数增加至四倍，同宽度全局注意力的矩阵规模约增加至十六倍。共享参数节省存储，并不消除注意力计算成本。必须同时报告 FLOPs、显存及推理速度。若成本过高，再单独考察窗口化或线性注意力，避免一开始引入过多结构变量。

2.3 如何判断该模块有效

除像素 AP 和 AUPRO 外，比较微小缺陷区域覆盖率、正常纹理误报与缺陷相对背景的标准化分数间隔。若模型只是产生更大的正常重建误差，则不能认为细节分支有效。

3 模块 B：局部扰动恢复训练

动机：高分辨率特征既可能强化缺陷信号，也可能让异常复制更容易。借鉴 DeCo-Diff 与 OneNIP，将局部受扰动输入恢复为正常目标。

$$\widetilde{F}_s = F_s + M_s \odot \epsilon_s, \qquad \widehat{F}_s = D_s(\widetilde{F}_s).$$

F_s 为冻结编码器的干净特征，M_s 为扰动掩码，ϵ_s 为扰动，D_s 为对应尺度的重建分支。不同尺度的掩码应映射自同一输入区域，减少跨尺度干净信息泄漏。

$$L_{\text{restore}} = \sum_s \left[\lambda_r \,\text{Mean}_{M_s=1} \|\widehat{F}_s - F_s\|_2^2 + \lambda_n \,\text{Mean}_{M_s=0} \|\widehat{F}_s - F_s\|_2^2 \right].$$

两类区域分别取平均，防止小面积扰动被正常背景淹没。空掩码区域需跳过对应项，避免除零。上述分区损失是本方案的扩展，不是引用论文的原公式。

建议覆盖小块、细长区域与弱幅值变化，并设置较大扰动对照。只在正常训练图上合成扰动；保证扰动投影至各尺度后仍非空。保留原版 jitter、仅局部扰动、二者结合的对照，防止将扰动总强度变化误认为新机制收益。

4 模块 C：分尺度残差校准与融合

先从正常训练或独立正常校准数据建立各尺度分数基准，再融合：

$$Z_s = \frac{S_s - \mu_s}{\sigma_s + \varepsilon}, \qquad S_{\text{mean}} = \sum_s w_s \,\text{Up}(Z_s), \quad S_{\max} = \max_s \text{Up}(Z_s).$$

$w_s \geq 0$ 且 $\sum_s w_s = 1$。先采用固定权重，随后再考虑可学习融合。统计量只从正常开发数据估计并在测试前冻结，不对每张测试异常图自身做 min-max 归一化。

加权平均较稳定，但可能稀释单尺度缺陷；最大值保留局部强响应，但也可能放大噪声。几何平均不能直接作为默认：若深层不响应微小缺陷，相乘会压低浅层有效信号。

这一校准是受 CADA 启发的简单起点，**不是原版 CADA 的复现**。单张图上的正仿射校准不改变像素排序，不能恢复空间细节；分尺度校准后融合的空间收益需另行验证。

5 消融实验与评价协议

编号	配置	验证目的
B0	原版 MoEAD	基线
B1	双分支，均为 14×14	分组与新增容量
B2	细节 28×28 ＋语义 14×14	空间细节保留
B3	B2 ＋局部扰动恢复	抑制异常复制
B4	B2 ＋校准融合	单独验证尺度校准
B5	B2 ＋恢复＋校准融合	组合收益

必要对照：仅提高原版输入分辨率；仅改变评分池化；共享与不共享专家；若资源允许，加入参数量相近的单分支对照。B3、B4、B5 使用一致的原始分尺度残差定义。

5.1 微小异常的定义

按原始图像标注的连通缺陷区域计算面积比例，而非将整张异常图统一标为“微小”。测试前固定面积分组规则，另报告细长缺陷的宽度或形状分组。可用固定面积比例区间形成预注册草案，但不能用测试结果反复选择最有利阈值。

5.2 指标与防止结果误读

- 主指标：固定正常误报率下的小缺陷召回率；明确连通区域命中的覆盖标准，避免仅一个像素超过阈值就计为成功。
- 辅助指标：像素 AP、AUPRO、图像 AUROC、正常纹理误报率，以及大缺陷性能是否下降。
- 分别报告逐类别平均和混合类别整体结果；保留原始分数与校准后分数对照。
- 阈值用留出的正常校准集确定；测试异常标注只用于最终评价。模型选择采用固定训练终点或独立开发集，不反复使用测试集选最优轮次。
- 相同输入尺寸、数据划分、训练预算及后处理。主要配置至少使用 3 个随机种子，报告均值与标准差。
- 在同一硬件、批量和精度条件下测量参数量、显存、FLOPs 及推理耗时。

5.3 实施优先级与失败判据

先执行 B0→B1→B2，确认细节分支是否改善微小缺陷检出。若正常纹理误报上升或计算成本不可接受，应先调整层选择和分辨率。随后独立测试 B3、B4，最后测试 B5。若收益仅来自评分池化或校准，应将论文贡献限定为评分机制，不能宣称特征表达能力已增强。

6 论文组织与参考文献

暂定题目：面向微小缺陷的细粒度多尺度特征匹配工业异常检测方法。

建议论证顺序：先展示微小缺陷在原版各层及融合后的响应变化，建立问题证据；再介绍细节保留、局部恢复和分尺度融合；最后通过独立消融说明每项改动的作用与代价。避免将多个已知模块的组合直接宣称为新颖贡献。

创新性边界：双分支、多尺度、扰动恢复及分数校准均有已有研究。论文价值需依赖针对 MoEAD 的具体结构、明确的问题诊断、可解释的机制及稳定实验收益。当前文献集合不是完整新颖性检索，正式投稿前仍需核查相关工作。

参考文献与作用定位

[1] Meng, S., Meng, W., Zhou, Q., Li, S., Hou, W., & He, S. MoEAD: A Parameter-efficient Model for Multi-class Anomaly Detection. ECCV, 2024.
论文全文；官方代码。用于基础架构、参数共享及原版实现核对。

[2] Guo, J., Lu, S., Zhang, W., Chen, F., Li, H., & Liao, H. Dinomaly: The Less Is More Philosophy in Multi-Class Unsupervised Anomaly Detection. CVPR, 2025.
https://arxiv.org/abs/2405.14325。用于语义分组、含噪瓶颈及分辨率实验依据。

[3] Beizaee, F., Lodygensky, G. A., Desrosiers, C., & Dolz, J. Correcting Deviations from Normality: A Reformulated Diffusion Model for Multi-Class Unsupervised Anomaly Detection. CVPR, 2025.
https://arxiv.org/abs/2503.19357。用于局部扰动和正常区域保持的启发。

[4] Gao, B.-B. Learning to Detect Multi-class Anomalies with Just One Normal Image Prompt. ECCV 2024；本次阅读为 2025 年上传的 arXiv v1。
https://arxiv.org/abs/2505.09264。用于正常目标恢复、分辨率及残差细化的启发。

[5] Guo, J., Han, H., Lu, S., Zhang, W., & Li, H. Absolute-Unified Multi-Class Anomaly Detection via Class-Agnostic Distribution Alignment. arXiv:2404.00724v2, 2024.
https://arxiv.org/abs/2404.00724。用于跨类别分数失配及正常基准校准。

交付说明：本文为研究与实验设计稿，不包含代码修改、训练结果或有效性承诺。服务器实验由研究者执行；后续依据结果修订模块选择和论文贡献。